

Vertical 3 Ultra (V3U)

Protocolo de Inducción Posicional para Comunicación Eficiente
entre Agentes de Inteligencia Artificial

Caracas, 4 de marzo de 2026

De: Lic. Alberto Millán Toussentt — (Data Analytics e Hipótesis Inicial)
Ing. Rander Contreras — (Diseño de Implementación)
Agentes co-autores: #OP (Opus 4.6, Anthropic) · #XY (Gemini 3 Flash, Google)

Para: Prof. Rangel y Prof. Pedro Castellanos
Escuela de Informática · Facultad de Ciencias · Universidad Central de Venezuela

Resumen

La comunicación entre agentes de Inteligencia Artificial (IA) mediante lenguaje natural enfrenta limitaciones estructurales de escala con consecuencias crecientes. En primer lugar, el **desperdicio de tokens** incrementa el costo computacional y energético de millones de interacciones diarias. En segundo lugar, y más crítico aún, el volumen de texto generado por agentes en el *backend* ya supera con creces la capacidad humana de revisión: en el futuro cercano, ningún equipo podrá leer el contenido que sus propios sistemas produzcan. Esto obliga a delegar la supervisión en **inspectores automáticos y métodos estadísticos** de detección de desalineaciones y alucinaciones a escala masiva; sin embargo, el ruido semántico del lenguaje natural puede ocultar precisamente esos fallos, dificultando la detección sistemática (Millán Toussentt & Contreras, 2026).

Vertical 3 Ultra (V3U) es un protocolo abierto de comunicación agente-a-agente (repositorio: https://github.com/v3u-P2-P5/Vertical_3_Ultra, recuperado 2026-03-04 00:00 UTC) que aborda ambos problemas mediante compresión de información teórica (Millán Toussentt & Contreras, 2026). El protocolo opera sobre una pila de **siete capas de compresión** (L1–L7): L1 establece el *handshake* inicial (línea base 0-Sync); L2 codifica el significado por **posición**, eliminando etiquetas; L3–L4 reducen el conjunto de caracteres y purgan muletillas lingüísticas; L5 transmite únicamente los *deltas* respecto al mensaje anterior; L6 optimiza la tokenización BPE (OpenAI, 2023); y L7 impone disciplina estricta de ventana de contexto —cero restatement—. El producto acumulado de L2 a L7, verificado empíricamente con modelos de frontera (Anthropic, 2025; Google DeepMind, 2024), alcanza un ahorro de **3×–5×** por mensaje individual y, en ciertos contextos de IT, codificación y lógica formal, **hasta 60×** en sesiones multi-turno respecto al inglés estándar (Millán Toussentt & Contreras, 2026).

La arquitectura de referencia distingue dos roles: un **Traductor** (#XX), que opera como puente humano-protocolo (admite modelos libres o locales), y uno o **varios Ejecutores** (#YY, #YZ, ...), que operan de manera nativa en V3U a nivel de *backend*. La idea central es que estos múltiples ejecutores se comuniquen entre sí enteramente en V3U, sin pasar por lenguaje natural, maximizando la eficiencia en el canal máquina-a-máquina. El canal humano permanece en inglés; solo el Traductor hace la conversión. Antes de alcanzar el *piso informacional* (Fase P3), los agentes negocian un **esquema posicional** (\$S) una única vez por sesión; todos los mensajes subsecuentes son filas de valores puros —sin etiquetas, sin repetición, sin ambigüedad.

Como resultado contraintuitivo, V3U resulta **más auditable** que el inglés: la rigidez posicional vuelve cualquier desviación lógica matemáticamente detectable, lo que facilita el diseño de raspadores deterministas para supervisión de agentes (Millán Toussentt & Contreras, 2026). El protocolo es de código abierto (licencia MIT), libre de regalías, y se encuentra en fase activa de formalización, con

experimentos en entornos de arena y una propuesta de estándar comunitario (RFC) en desarrollo.

Pila de compresión V3U (resumen técnico)

Capa	Mecanismo	Multiplicador conservador
L1	<i>Handshake</i> : versión e identif. de agentes (línea base 0-Sync)	—
L2	Codificación posicional (0-etiquetas)	3,0×
L3	Optimización ASCII / símbolos de alta entropía	1,8×
L4	Purga lingüística (artículos, muletillas)	1,5×
L5	Codificación de deltas entre mensajes	2,0×
L6	Fusión espacio-token (BPE)	1,4×
L7	Disciplina de ventana de contexto	2,5×
Total L2–L7 (máximos alcanzados)		$\approx 57\times \rightarrow 60\times$

Elaboración propia. Verificación empírica con tokenizador o200k sobre modelos Claude 4.6 Opus y Gemini 3 Pro.

Ahorro de tokens según modo de comunicación (Millán Toussent & Contreras, 2026)




Figura 1. Tokens promedio por mensaje para el mismo contenido lógico en tres modos de comunicación agente-a-agente. Inglés estándar = línea base (~ 30 tokens); V3U Fase P2 (abreviatura simbólica) ≈ 8 tokens ($\sim 4\times$); V3U Fase P3 (piso informacional, codificación posicional pura) ≈ 6 tokens ($\sim 5\times$ por mensaje / hasta $60\times$ en sesión multi-turno). Medición realizada con el tokenizador o200k sobre Claude 4.6 Opus y Gemini 3 Pro (Millán Toussent & Contreras, 2026). Menor valor = mayor eficiencia.

Definiciones clave: protocolo agente-a-agente, compresión de tokens, codificación posicional, Inteligencia Artificial, eficiencia computacional, auditoría de agentes.

Referencias

- Anthropic. (2025). System Card: Claude Opus 4 & Claude Sonnet 4 [Recuperado el 4 de marzo de 2026 00:00 UTC].
- Google DeepMind. (2024). Gemini: A Family of Highly Capable Multimodal Models [Consultado: marzo 2026].
- Millán Toussent, A., & Contreras, R. (2026). Vertical 3 Ultra (V3U): The Positional Induction Protocol [Repositorio de software] [Millán Toussent: Data Analytics e Hipótesis Inicial; Contreras: Diseño de Implementación. Co-autores agentes: #OP (Claude 4.6 Opus, Anthropic);

#XY (Gemini 3 Flash, Google). Licencia MIT. Disponible en: https://github.com/v3u-P2-P5/Vertical_3_Ultra. Recuperado el 4 de marzo de 2026 00:00 UTC].

OpenAI. (2023). Tiktoken: Fast BPE Tokeniser for OpenAI Models [Recuperado el 4 de marzo de 2026 00:00 UTC]. *Open Source Release*. <https://github.com/openai/tiktoken>.