

Vertical 3 Ultra (V3U)

Protocolo de Inducción Posicional para Comunicación Eficiente
entre Agentes de Inteligencia Artificial

Caracas, 4 de marzo de 2026

De: Lic. Alberto Millán Toussentt — (Data Analytics e Hipótesis Inicial)
Ing. Rander Contreras — (Diseño de Implementación)
Agentes co-autores: #OP (Opus 4.6, Anthropic) · #XY (Gemini 3 Flash, Google)

Para: Prof. Rangel y Prof. Pedro Castellanos
Escuela de Informática · Facultad de Ciencias · Universidad Central de Venezuela

Resumen

La comunicación entre agentes de Inteligencia Artificial (IA) mediante lenguaje natural enfrenta limitaciones estructurales de escala con consecuencias crecientes. En primer lugar, el **desperdicio de tokens** incrementa el costo computacional y energético de millones de interacciones diarias. En segundo lugar, y más crítico aún, el volumen de texto generado por agentes en el *backend* ya supera con creces la capacidad humana de revisión: en el futuro cercano, ningún equipo podrá leer el contenido que sus propios sistemas produzcan. Esto obliga a delegar la supervisión en **inspectores automáticos y métodos estadísticos** de detección de desalineaciones y alucinaciones a escala masiva; sin embargo, el ruido semántico del lenguaje natural puede ocultar precisamente esos fallos, dificultando la detección sistemática (Millán Toussentt & Contreras, 2026).

Millán Toussentt y Contreras (2026) proponen **Vertical 3 Ultra (V3U)**, un protocolo abierto de comunicación agente-a-agente (repositorio: https://github.com/v3u-P2-P5/Vertical_3_Ultra, recuperado 2026-03-04 00:00 UTC) que aborda ambos problemas mediante compresión de información teórica. El protocolo opera sobre una pila de **siete capas de compresión** (L1–L7): L1 establece el *handshake* inicial (línea base 0-Sync); L2 codifica el significado por **posición**, eliminando etiquetas; L3–L4 reducen el conjunto de caracteres y purgan muletillas lingüísticas; L5 transmite únicamente los *deltas* respecto al mensaje anterior; L6 optimiza la tokenización BPE (OpenAI, 2023); y L7 impone disciplina estricta de ventana de contexto —cero restatement—. El producto acumulado de L2 a L7, verificado empíricamente con modelos de frontera (Anthropic, 2025; Google DeepMind, 2024), alcanza un ahorro de $3\times$ – $5\times$ por mensaje individual y, en ciertos contextos de IT, codificación y lógica formal, **hasta $60\times$** en sesiones multi-turno respecto al inglés estándar.

La arquitectura de referencia distingue dos roles: un **Traductor** (#XX), que opera como puente humano-protocolo (admite modelos libres o locales), y uno o **varios Ejecutores** (#YY, #YZ, ...), que operan de manera nativa en V3U a nivel de *backend*. La idea central es que estos múltiples ejecutores se comuniquen entre sí enteramente en V3U, sin pasar por lenguaje natural, maximizando la eficiencia en el canal máquina-a-máquina. El canal humano permanece en inglés; solo el Traductor hace la conversión. Antes de alcanzar el *piso informacional* (Fase P3), los agentes negocian un **esquema posicional** (\$S) una única vez por sesión; todos los mensajes subsecuentes son filas de valores puros —sin etiquetas, sin repetición, sin ambigüedad.

Como resultado contraintuitivo, V3U resulta **más auditable** que el inglés: la rigidez posicional vuelve cualquier desviación lógica matemáticamente detectable, lo que facilita el diseño de raspadores deterministas para supervisión de agentes. El protocolo es de código abierto (licencia MIT), libre de regalías, y se encuentra en fase activa de formalización, con experimentos en entornos de arena y una propuesta de estándar comunitario (RFC) en desarrollo.

Pila de compresión V3U (resumen técnico)

Capa	Mecanismo	Multiplicador conservador
L1	<i>Handshake</i> : versión e identif. de agentes (línea base 0-Sync)	—
L2	Codificación posicional (0-etiquetas)	3,0×
L3	Optimización ASCII / símbolos de alta entropía	1,8×
L4	Purga lingüística (artículos, muletillas)	1,5×
L5	Codificación de deltas entre mensajes	2,0×
L6	Fusión espacio-token (BPE)	1,4×
L7	Disciplina de ventana de contexto	2,5×
Total L2–L7 (máximos alcanzados)		≈ 57× → 60×

Elaboración propia. Verificación empírica con tokenizador o200k sobre modelos Claude 4.6 Opus y Gemini 3 Pro.

Ahorro de tokens según modo de comunicación




Figura 1. Tokens promedio por mensaje para el mismo contenido lógico en tres modos de comunicación agente-a-agente. Inglés estándar = línea base (~30 tokens); V3U Fase P2 (abreviatura simbólica) ≈ 8 tokens (~4×); V3U Fase P3 (piso informacional, codificación posicional pura) ≈ 6 tokens (~5× por mensaje / hasta 60× en sesión multi-turno). Medición realizada con el tokenizador o200k sobre Claude 4.6 Opus y Gemini 3 Pro (Millán Toussent & Contreras, 2026). Menor valor = mayor eficiencia.

Definiciones clave: protocolo agente-a-agente, compresión de tokens, codificación posicional, Inteligencia Artificial, eficiencia computacional, auditoría de agentes.

Referencias

- Anthropic. (2025). System Card: Claude Opus 4 & Claude Sonnet 4 [Recuperado el 4 de marzo de 2026 00:00 UTC].
- Google DeepMind. (2024). Gemini: A Family of Highly Capable Multimodal Models [Consultado: marzo 2026].
- Millán Toussent, A., & Contreras, R. (2026). Vertical 3 Ultra (V3U): The Positional Induction Protocol [Repositorio de software] [Millán Toussent: Data Analytics e Hipótesis Inicial; Contreras: Diseño de Implementación. Co-autores agentes: #0P (Claude 4.6 Opus, Anthropic); #XY (Gemini 3 Flash, Google). Licencia MIT. Disponible en: https://github.com/v3u-P2-P5/Vertical_3_Ultra. Recuperado el 4 de marzo de 2026 00:00 UTC].
- OpenAI. (2023). Tiktoken: Fast BPE Tokeniser for OpenAI Models [Recuperado el 4 de marzo de 2026 00:00 UTC]. *Open Source Release*. <https://github.com/openai/tiktoken>.